


TAREA #2 DEEP LEARNING

El objetivo de esta tarea fue mejorar el rendimiento de una red neuronal convolucional (CNN) utilizada para segmentación de imágenes de mascotas, utilizando el dataset **Oxford-IIIT Pet**. Para ello, se comparó una **arquitectura inicial base** con una **arquitectura optimizada**, evaluando su rendimiento tanto cuantitativo como cualitativo.



En la función `get_model_Optimizado(...)` se implementa una red CNN modificada respecto a la original con los siguientes ajustes:

- **Tamaño del kernel aumentado a 5x5**, con el fin de capturar patrones espaciales más amplios en cada convolución.
- **Reducción de bloques principales a 2**, lo que disminuye la profundidad de la red, mejorando la estabilidad del entrenamiento y reduciendo el riesgo de sobreajuste.
- **Filtros utilizados: [64, 128]**, en lugar de extender hasta 256 como en el modelo original, para controlar la complejidad sin perder capacidad representativa.

Esto redujo la complejidad de la red, mejoró la estabilidad y mantuvo o incluso aumentó la calidad de segmentación. Se evaluaron ambos modelos con las siguientes métricas: Dice Coefficient, IoU (Intersection over Union) y Loss (pérdida) durante 50 épocas.




- Ambos modelos alcanzan métricas altas (> 0.80), lo que indica un buen desempeño general en segmentación.
- El **modelo optimizado** presenta menor varianza y curvas más estables a lo largo de las épocas.
- El **modelo inicial** muestra oscilaciones más marcadas, con picos y caídas abruptas, lo que podría indicar **overfitting parcial** o sensibilidad a ciertas muestras del dataset.
- El **modelo optimizado** supera al **modelo inicial**, manteniéndose en torno a un **Dice ~ 0.90** y un **IoU ~ 0.82** en validación (En el notebook se ve el entrenamiento y validación del modelo optimizado).



- **Loss:**

Si bien, el **modelo inicial** presenta un comportamiento más estable, con valores de pérdida de validación relativamente bajos en la mayor parte del entrenamiento las métricas de segmentación (**Dice e IoU**) indican que el optimizado genera predicciones más precisas, lo que deja en evidencia que una mayor pérdida no siempre implica peor segmentación.



El modelo optimizado demuestra ser más consistente y robusto, especialmente en escenarios sensibles al ruido y fluctuaciones durante el entrenamiento. Además, mejora el rendimiento general sin aumentar la complejidad del modelo, lo que lo convierte en una solución más eficiente y confiable para tareas de segmentación multiclase sobre imágenes reales.